# Clasificación Automatizada de Gliomas Cerebrales mediante el Análisis de Mutaciones Genéticas y Machine Learning

Frank Arone
Machine Learning
*Asesor: Victor E. Martínez*
*Universidad de Ingeniería y Tecnología (UTEC)*

***Resumen*—Este proyecto aborda la clasificación automatizada de gliomas cerebrales mediante datos clínicos y mutacionales. El objetivo fue desarrollar modelos de Machine Learning capaces de diferenciar entre gliomas de bajo grado (LGG) y glioblastomas multiformes (GBM), utilizando el dataset *Glioma Grading Clinical and Mutation Features* del repositorio UCI. Se evaluaron cuatro modelos supervisados: Regresión Logística, SVM, Random Forest y XGBoost. Los resultados mostraron que XGBoost obtuvo la mayor capacidad discriminativa global, con un ROC-AUC de 0.924 en prueba y 0.920 en validación cruzada. Asimismo, la Regresión Logística alcanzó el mejor F1-score promedio en validación cruzada. El análisis de importancia de variables identificó a IDH1 como el marcador más influyente para diferenciar LGG y GBM.**

***Index Terms*—Machine Learning, glioma, LGG, GBM, clasificación supervisada, mutaciones genéticas, XGBoost, bioinformática.**

## I. Introducción

LOS gliomas son tumores del sistema nervioso central cuya clasificación tiene un impacto directo en el pronóstico y en la toma de decisiones terapéuticas. En particular, la diferenciación entre gliomas de bajo grado (LGG) y glioblastomas multiformes (GBM) es clínicamente relevante, ya que ambos presentan diferencias importantes en agresividad, evolución y respuesta al tratamiento. Tradicionalmente, esta clasificación depende de evaluaciones histopatológicas y moleculares realizadas por especialistas, lo que puede implicar procesos costosos y tiempos prolongados de análisis.

En los últimos años, la clasificación molecular de gliomas ha cobrado mayor importancia debido al rol de marcadores como IDH1, IDH2, TP53, ATRX, EGFR y PTEN. La clasificación moderna de tumores del sistema nervioso central integra criterios histológicos y moleculares, lo que refuerza la necesidad de herramientas computacionales capaces de procesar datos clínico-genómicos de manera eficiente [2], [3].

El objetivo general de este proyecto es implementar y evaluar modelos de Machine Learning para clasificar automáticamente pacientes con glioma en LGG o GBM a partir de características clínicas y mutacionales. Los objetivos específicos son: comparar el desempeño de modelos supervisados de clasificación, identificar las variables más importantes para la predicción y complementar el análisis mediante técnicas de reducción de dimensionalidad e interpretación de variables.

Para este estudio se utilizó el dataset *Glioma Grading Clinical and Mutation Features*, disponible en el repositorio UCI Machine Learning Repository. Este conjunto de datos contiene 839 pacientes y 23 variables originales, incluyendo características clínicas y mutaciones genéticas binarias [1].

## II. Revisión Bibliográfica

La clasificación de gliomas ha evolucionado desde un enfoque principalmente histopatológico hacia una clasificación integrada que incorpora marcadores moleculares. La quinta edición de la clasificación de tumores del sistema nervioso central de la Organización Mundial de la Salud enfatiza el uso de alteraciones moleculares como IDH y 1p/19q para definir entidades tumorales con mayor precisión biológica [2]. De forma complementaria, las guías EANO resaltan que el diagnóstico y tratamiento de gliomas difusos en adultos debe considerar la información molecular junto con los criterios clínicos y radiológicos [3].

Diversos estudios han demostrado que mutaciones en IDH1 e IDH2 están asociadas con subtipos específicos de glioma y con diferencias pronósticas relevantes. Asimismo, alteraciones en TP53, ATRX, EGFR y PTEN han sido relacionadas con progresión tumoral, subtipo molecular y agresividad biológica [6]–[8]. Por ello, el análisis computacional de perfiles genéticos representa una oportunidad para apoyar la clasificación tumoral.

Desde la perspectiva de Machine Learning, el problema corresponde a una tarea de clasificación supervisada binaria, donde cada paciente posee una etiqueta conocida: LGG o GBM. En este contexto, la Regresión Logística permite construir un modelo base interpretable, mientras que SVM permite evaluar fronteras de decisión no lineales mediante kernels [14]. Random Forest es útil para datos tabulares por su robustez y capacidad de estimar importancia de variables [13]. Por otro lado, XGBoost es un método de boosting basado en árboles que ha mostrado alto desempeño en problemas tabulares de clasificación [15].

Además de la predicción, la interpretabilidad es especialmente importante en aplicaciones biomédicas. Métodos como la importancia de variables, la importancia por permutación y SHAP permiten analizar qué características influyen más en la decisión del modelo [17], [18]. Finalmente, técnicas de

reducción de dimensionalidad como PCA, t-SNE y UMAP permiten explorar visualmente la estructura interna de los datos y posibles agrupamientos entre pacientes [21], [22].

## III. Metodología

### III-A. Dataset

El dataset utilizado fue *Glioma Grading Clinical and Mutation Features*, obtenido del repositorio UCI Machine Learning Repository [1]. La variable objetivo fue *Grade*, codificada como una clasificación binaria entre LGG y GBM. Las variables predictoras incluyeron edad al diagnóstico, género, raza y mutaciones genéticas binarias como IDH1, TP53, ATRX, PTEN, EGFR, CIC, MUC16, PIK3CA, NF1, PIK3R1, FUBP1, RB1, NOTCH1, BCOR, CSMD3, SMARCA4, GRIN2A, IDH2, FAT4 y PDGFRA.

### III-B. Preprocesamiento

Primero se verificó la estructura del dataset, la distribución de clases y la presencia de valores nulos. No se encontraron datos faltantes, por lo que no fue necesario aplicar imputación. La variable categórica *Race* fue transformada mediante *One-Hot Encoding*, generando variables binarias adicionales. De esta manera, el conjunto final quedó compuesto únicamente por variables numéricas.

Para evitar sesgos en la proporción de clases, se utilizó una división estratificada entre entrenamiento y prueba, con 80 % de los datos para entrenamiento y 20 % para prueba. Adicionalmente, los modelos sensibles a la escala, como Regresión Logística y SVM, fueron implementados dentro de un *pipeline* con *StandardScaler*.

### III-C. Modelos Implementados

Se evaluaron cuatro modelos supervisados de clasificación binaria:

- **Regresión Logística:** utilizada como modelo base interpretable. Permite analizar la relación entre las variables y la probabilidad de pertenecer a una clase.
- **SVM con kernel RBF:** utilizada para capturar posibles fronteras no lineales entre LGG y GBM.
- **Random Forest:** modelo de ensamble basado en múltiples árboles de decisión, útil para datos tabulares y análisis de importancia de variables.
- **XGBoost:** modelo de boosting basado en árboles, seleccionado como candidato principal por su capacidad para capturar relaciones no lineales y mejorar la separación entre clases.

### III-D. Validación y Métricas

Para evaluar los modelos se utilizaron las métricas Accuracy, Precision, Recall, F1-score y ROC-AUC. Accuracy mide el porcentaje total de predicciones correctas; Precision mide la proporción de predicciones positivas correctas; Recall mide la capacidad de detectar correctamente la clase positiva; F1-score resume el equilibrio entre Precision y Recall; y ROC-AUC evalúa la capacidad global del modelo para separar ambas clases [19].

Tabla I
Resultados en el conjunto de prueba

| Modelo | Accuracy | Precision | Recall | F1-score | ROC-AUC |
|---|---|---|---|---|---|
| Logistic Regression | 0.857 | 0.811 | 0.857 | 0.833 | 0.918 |
| SVM RBF | 0.863 | 0.805 | 0.886 | 0.844 | 0.910 |
| Random Forest | 0.792 | 0.761 | 0.729 | 0.745 | 0.902 |
| XGBoost | 0.851 | 0.800 | 0.857 | 0.828 | 0.924 |

Tabla II
Resultados de validación cruzada estratificada 10-fold

| Modelo | Accuracy CV | Precision CV | Recall CV | F1 CV | ROC-AUC CV |
|---|---|---|---|---|---|
| Logistic Regression | 0.868 | 0.812 | 0.898 | 0.851 | 0.918 |
| SVM RBF | 0.858 | 0.794 | 0.901 | 0.843 | 0.907 |
| Random Forest | 0.840 | 0.799 | 0.833 | 0.814 | 0.905 |
| XGBoost | 0.857 | 0.807 | 0.872 | 0.837 | 0.920 |

Además del conjunto de prueba, se aplicó validación cruzada estratificada con $k = 10$, con el objetivo de evaluar la estabilidad del desempeño y reducir la dependencia de una única partición de datos [20].

### III-E. Interpretabilidad y Análisis Exploratorio

La interpretabilidad se evaluó mediante tres enfoques: importancia de variables en Random Forest, importancia de variables en XGBoost e importancia por permutación. También se analizaron los coeficientes de la Regresión Logística como referencia interpretable. Para complementar el análisis, se aplicaron PCA y t-SNE como técnicas de reducción de dimensionalidad. Finalmente, se incluyó K-Means solo como análisis exploratorio no supervisado, no como modelo principal, ya que el objetivo central del proyecto es la clasificación supervisada.

## IV. Resultados

### IV-A. Comparación de Modelos en el Conjunto de Prueba

La Tabla I presenta los resultados obtenidos en el conjunto de prueba. Los cuatro modelos mostraron una capacidad predictiva aceptable, aunque con diferencias entre métricas. SVM obtuvo la mayor exactitud, mientras que XGBoost obtuvo el mayor ROC-AUC, lo que indica una mejor capacidad global para separar LGG de GBM.

Aunque XGBoost no obtuvo la mayor exactitud, sí alcanzó el mejor ROC-AUC. Esto indica que el modelo tuvo la mejor capacidad discriminativa general, especialmente al analizar las probabilidades de clasificación y no solo las predicciones finales.

### IV-B. Validación Cruzada

La Tabla II muestra los resultados de la validación cruzada estratificada con 10 pliegues. XGBoost obtuvo el mayor ROC-AUC promedio, mientras que la Regresión Logística alcanzó el mayor F1-score promedio. Esto evidencia que XGBoost separa mejor ambas clases a nivel global, pero la Regresión Logística mantiene un desempeño competitivo y más interpretable.

La Figura 1 presenta las curvas ROC de los modelos evaluados. La curva de XGBoost obtuvo el mayor área bajo la curva, reforzando su selección como modelo final en términos de capacidad de separación entre LGG y GBM.

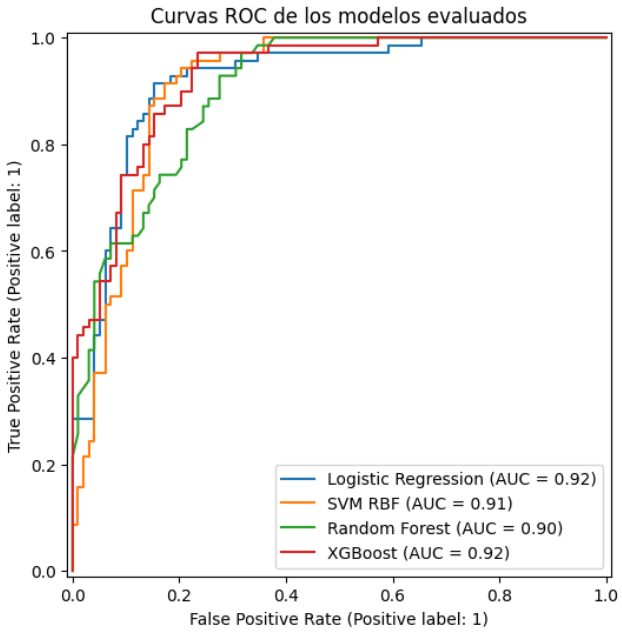



Figura 1. Curvas ROC de los modelos evaluados para la clasificación LGG vs GBM.

```
[[83 15]
 [10 60]]
              precision    recall  f1-score   support

           0       0.89      0.85      0.87        98
           1       0.80      0.86      0.83        70

    accuracy                           0.85       168
   macro avg       0.85      0.85      0.85       168
weighted avg       0.85      0.85      0.85       168
```

Figura 2. Matriz de confusión del modelo XGBoost en el conjunto de prueba.

### *IV-C. Evaluación del Modelo XGBoost*

La matriz de confusión del modelo XGBoost se presenta en la Figura 2. El modelo clasificó correctamente la mayoría de pacientes de ambas clases. Sin embargo, se observaron 15 casos LGG clasificados como GBM y 10 casos GBM clasificados como LGG. En un contexto clínico, estos errores son relevantes, ya que una clasificación incorrecta puede afectar la interpretación del grado tumoral.

### *IV-D. Importancia de Variables*

El análisis de importancia de variables permitió identificar qué características fueron más influyentes en la clasificación. La Figura 3 muestra la importancia por permutación del modelo XGBoost. Este análisis evidenció que IDH1 fue la variable más determinante para el rendimiento del modelo.

La importancia de IDH1 es coherente con la literatura biomédica, ya que esta mutación es un marcador molecular fundamental en la clasificación moderna de gliomas. Además, otras variables como edad al diagnóstico, IDH2, CIC, PTEN, ATRX, NF1 y EGFR también aparecieron entre las variables relevantes, lo que sugiere que la clasificación depende de una combinación de información clínica y genética.

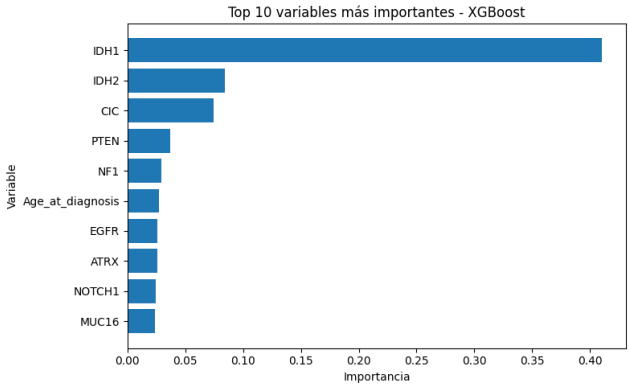



Figura 3. Importancia de variables por permutación para el modelo XGBoost.

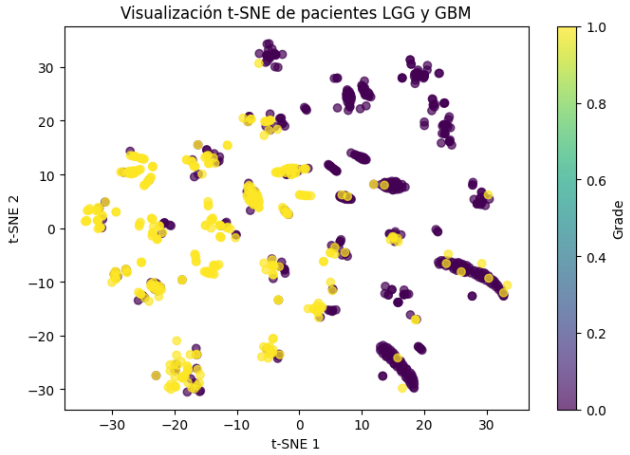



Figura 4. Visualización t-SNE de los pacientes según su clase LGG o GBM.

### *IV-E. Visualización con t-SNE*

Se utilizó t-SNE para explorar visualmente la estructura interna del dataset. Esta técnica permite representar datos de alta dimensión en un espacio bidimensional preservando relaciones de vecindad local [21]. La Figura 4 muestra la proyección de los pacientes según sus características clínicas y mutacionales.

La visualización t-SNE no fue utilizada como modelo predictivo principal, sino como herramienta exploratoria. Su objetivo fue observar si los pacientes presentaban agrupamientos no lineales relacionados con las clases LGG y GBM.

### *IV-F. Comparación por Grupo de Variables*

Para evaluar el aporte relativo de las variables clínicas y mutacionales, se entrenó XGBoost usando tres grupos de características: solo clínicas, solo mutaciones y la combinación de ambas. Los resultados se presentan en la Tabla III y en la Figura 5.

El modelo basado únicamente en mutaciones superó al modelo basado solo en variables clínicas. Sin embargo, el mejor rendimiento se obtuvo al combinar ambos tipos de información. Esto indica que la información genética aporta mayor capacidad predictiva, pero la integración con variables clínicas mejora la clasificación final.

Tabla III
COMPARACIÓN DE RENDIMIENTO POR GRUPO DE VARIABLES

| Grupo de variables | Número de variables | ROC-AUC |
|---|---|---|
| Solo clínicas | 5 | 0.829 |
| Solo mutaciones | 20 | 0.906 |
| Clínicas + mutaciones | 25 | 0.924 |

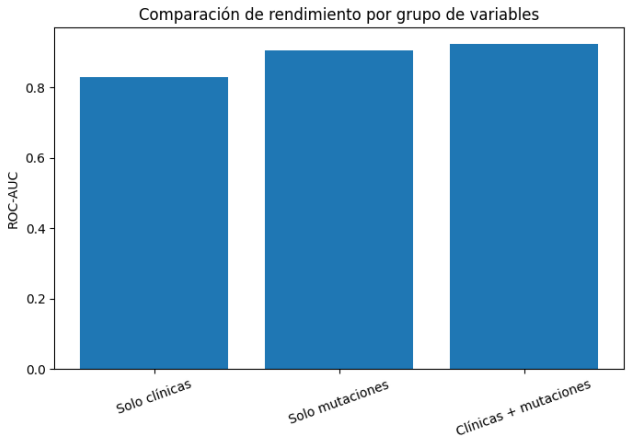



Figura 5. Comparación del ROC-AUC usando variables clínicas, mutacionales y combinadas.

### *IV-G. Clustering Exploratorio*

Aunque el proyecto corresponde a una tarea de clasificación supervisada, se aplicó K-Means con dos grupos como análisis exploratorio. Este procedimiento permitió evaluar si los perfiles clínico-mutacionales generaban agrupamientos similares a las clases reales sin utilizar directamente las etiquetas. El análisis obtuvo un Adjusted Rand Index de 0.502 y un Normalized Mutual Information de 0.425, lo que indica una relación moderada entre los clusters encontrados y las clases LGG/GBM.

Este resultado sugiere que existe cierta estructura interna en los datos, pero no suficiente para reemplazar los modelos supervisados. Por ello, el clustering fue considerado únicamente como complemento exploratorio y no como enfoque principal del proyecto.

## V. CONCLUSIONES

El proyecto permitió implementar y comparar modelos de Machine Learning para la clasificación automatizada de gliomas cerebrales a partir de datos clínicos y mutacionales. Los resultados demostraron que el problema puede abordarse adecuadamente como una tarea de clasificación supervisada binaria, diferenciando entre LGG y GBM.

XGBoost fue el modelo con mayor capacidad discriminativa global, alcanzando un ROC-AUC de 0.924 en el conjunto de prueba y 0.920 en validación cruzada. Esto indica que el modelo fue el más efectivo para separar ambas clases a nivel probabilístico. Sin embargo, la Regresión Logística obtuvo el mayor F1-score promedio en validación cruzada, lo que muestra que un modelo más simple e interpretable también puede alcanzar un desempeño competitivo.

El análisis de importancia de variables identificó a IDH1 como el marcador más relevante para la clasificación. Este hallazgo es consistente con el conocimiento biomédico actual sobre gliomas, donde las mutaciones en IDH son fundamentales para la clasificación molecular. Además, el análisis por grupos de variables mostró que las mutaciones genéticas aportan más información predictiva que las variables clínicas por separado, aunque la mejor clasificación se obtuvo al combinar ambas fuentes de información.

Finalmente, las técnicas exploratorias como t-SNE y K-Means permitieron observar una estructura parcial en los datos, pero no sustituyen a los modelos supervisados. En conjunto, los resultados respaldan el uso de Machine Learning como herramienta de apoyo computacional para el análisis de perfiles clínico-genómicos en gliomas.

## VI. TRABAJO FUTURO

Como trabajo futuro, se recomienda ampliar el análisis con datasets externos como TCGA o CGGA para evaluar la generalización del modelo en poblaciones diferentes. También sería conveniente incorporar validación clínica independiente, ya que los resultados actuales provienen de un dataset público y no de una cohorte hospitalaria local.

Otra mejora posible consiste en utilizar métodos avanzados de interpretabilidad, como SHAP, para analizar el efecto individual de cada variable en las predicciones del modelo. Asimismo, se podría implementar UMAP como alternativa a t-SNE, debido a su capacidad para preservar mejor parte de la estructura global de los datos y su mayor eficiencia computacional [22].

Finalmente, una línea futura de mayor complejidad sería integrar datos tabulares clínico-mutacionales con imágenes médicas, como resonancias magnéticas. En ese caso, podrían utilizarse modelos multimodales que combinen clasificadores tabulares con redes convolucionales, siempre que se disponga de un dataset suficientemente grande y correctamente etiquetado.

## CÓDIGO IMPLEMENTADO

El código implementado, junto con el notebook de experimentación en Google Colab, se encuentra disponible en el siguiente enlace:

https://drive.google.com/file/d/
1eTG7iHYwyem5sGQbRcVXQj8QkIJIavLe/view?usp=
sharing

## REFERENCIAS

[1] UCI Machine Learning Repository, “Glioma Grading Clinical and Mutation Features Dataset,” 2022. [Online]. Available: https://archive.ics.uci.edu/dataset/759/glioma+grading+clinical+and+mutation+features

[2] D. N. Louis, A. Perry, P. Wesseling, D. J. Brat, I. A. Cree, D. Figarella-Branger, C. Hawkins, H. K. Ng, S. M. Pfister, G. Reifenberger, R. Soffietti, A. von Deimling, and D. W. Ellison, “The 2021 WHO Classification of Tumors of the Central Nervous System: a summary,” *Neuro-Oncology*, vol. 23, no. 8, pp. 1231–1251, 2021. doi: https://doi.org/10.1093/neuonc/noab106

[3] M. Weller *et al.*, “EANO guidelines on the diagnosis and treatment of diffuse gliomas of adulthood,” *Nature Reviews Clinical Oncology*, vol. 18, pp. 170–186, 2021. doi: https://doi.org/10.1038/s41571-020-00447-z

[4] H. Yan *et al.*, "IDH1 and IDH2 mutations in gliomas," *The New England Journal of Medicine*, vol. 360, no. 8, pp. 765–773, 2009. doi: https://doi.org/10.1056/NEJMoa0808710

[5] D. W. Parsons *et al.*, "An integrated genomic analysis of human glioblastoma multiforme," *Science*, vol. 321, no. 5897, pp. 1807–1812, 2008. doi: https://doi.org/10.1126/science.1164382

[6] C. W. Brennan *et al.*, "The somatic genomic landscape of glioblastoma," *Cell*, vol. 155, no. 2, pp. 462–477, 2013. doi: https://doi.org/10.1016/j.cell.2013.09.034

[7] The Cancer Genome Atlas Research Network, "Comprehensive, integrative genomic analysis of diffuse lower-grade gliomas," *The New England Journal of Medicine*, vol. 372, no. 26, pp. 2481–2498, 2015. doi: https://doi.org/10.1056/NEJMoa1402121

[8] M. Ceccarelli *et al.*, "Molecular profiling reveals biologically discrete subsets and pathways of progression in diffuse glioma," *Cell*, vol. 164, no. 3, pp. 550–563, 2016. doi: https://doi.org/10.1016/j.cell.2015.12.028

[9] R. G. W. Verhaak *et al.*, "Integrated genomic analysis identifies clinically relevant subtypes of glioblastoma characterized by abnormalities in PDGFRA, IDH1, EGFR, and NF1," *Cancer Cell*, vol. 17, no. 1, pp. 98–110, 2010. doi: https://doi.org/10.1016/j.ccr.2009.12.020

[10] National Cancer Institute, "The Cancer Genome Atlas Program," Genomic Data Commons Data Portal. [Online]. Available: https://portal.gdc.cancer.gov/

[11] E. Cerami *et al.*, "The cBio Cancer Genomics Portal: an open platform for exploring multidimensional cancer genomics data," *Cancer Discovery*, vol. 2, no. 5, pp. 401–404, 2012. doi: https://doi.org/10.1158/2159-8290.CD-12-0095

[12] J. Gao *et al.*, "Integrative analysis of complex cancer genomics and clinical profiles using the cBioPortal," *Science Signaling*, vol. 6, no. 269, p. pl1, 2013. doi: https://doi.org/10.1126/scisignal.2004088

[13] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. doi: https://doi.org/10.1023/A:1010933404324

[14] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, pp. 273–297, 1995. doi: https://doi.org/10.1007/BF00994018

[15] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794. doi: https://doi.org/10.1145/2939672.2939785

[16] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: https://jmlr.org/papers/v12/pedregosa11a.html

[17] A. Altmann, L. Toloşi, O. Sander, and T. Lengauer, "Permutation importance: a corrected feature importance measure," *Bioinformatics*, vol. 26, no. 10, pp. 1340–1347, 2010. doi: https://doi.org/10.1093/bioinformatics/btq134

[18] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems*, vol. 30, 2017. [Online]. Available: https://arxiv.org/abs/1705.07874

[19] A. P. Bradley, "The use of the area under the ROC curve in the evaluation of machine learning algorithms," *Pattern Recognition*, vol. 30, no. 7, pp. 1145–1159, 1997. doi: https://doi.org/10.1016/S0031-3203(96)00142-2

[20] N. Japkowicz and S. Stephen, "The class imbalance problem: a systematic study," *Intelligent Data Analysis*, vol. 6, no. 5, pp. 429–449, 2002. doi: https://doi.org/10.3233/IDA-2002-6504

[21] L. van der Maaten and G. Hinton, "Visualizing data using t-SNE," *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008. [Online]. Available: https://jmlr.org/papers/v9/vandermaaten08a.html

[22] L. McInnes, J. Healy, N. Saul, and L. Großberger, "UMAP: Uniform Manifold Approximation and Projection," *Journal of Open Source Software*, vol. 3, no. 29, p. 861, 2018. doi: https://doi.org/10.21105/joss.00861

[23] U. Baid *et al.*, "The RSNA-ASNR-MICCAI BraTS 2021 Benchmark on Brain Tumor Segmentation and Radiogenomic Classification," *arXiv preprint arXiv:2107.02314*, 2021. [Online]. Available: https://arxiv.org/abs/2107.02314

[24] E. Calabrese *et al.*, "The University of California San Francisco Preoperative Diffuse Glioma MRI Dataset," *arXiv preprint arXiv:2109.00356*, 2021. [Online]. Available: https://arxiv.org/abs/2109.00356